# TAREA #1:

# Hankel-SVD-Entropy-Fourier
# +
# SNN-SGDM

**Prof. NIBALDO RODRÍGUEZ A.**

# OBJETIVO

- Implementar y evaluar el rendimiento de un modelo de red neuronal superficial para clasificación de datos de IoT usando matriz Hankel-SVD y Entropía Spectral de Fourier .

# Etapas del Modelo:

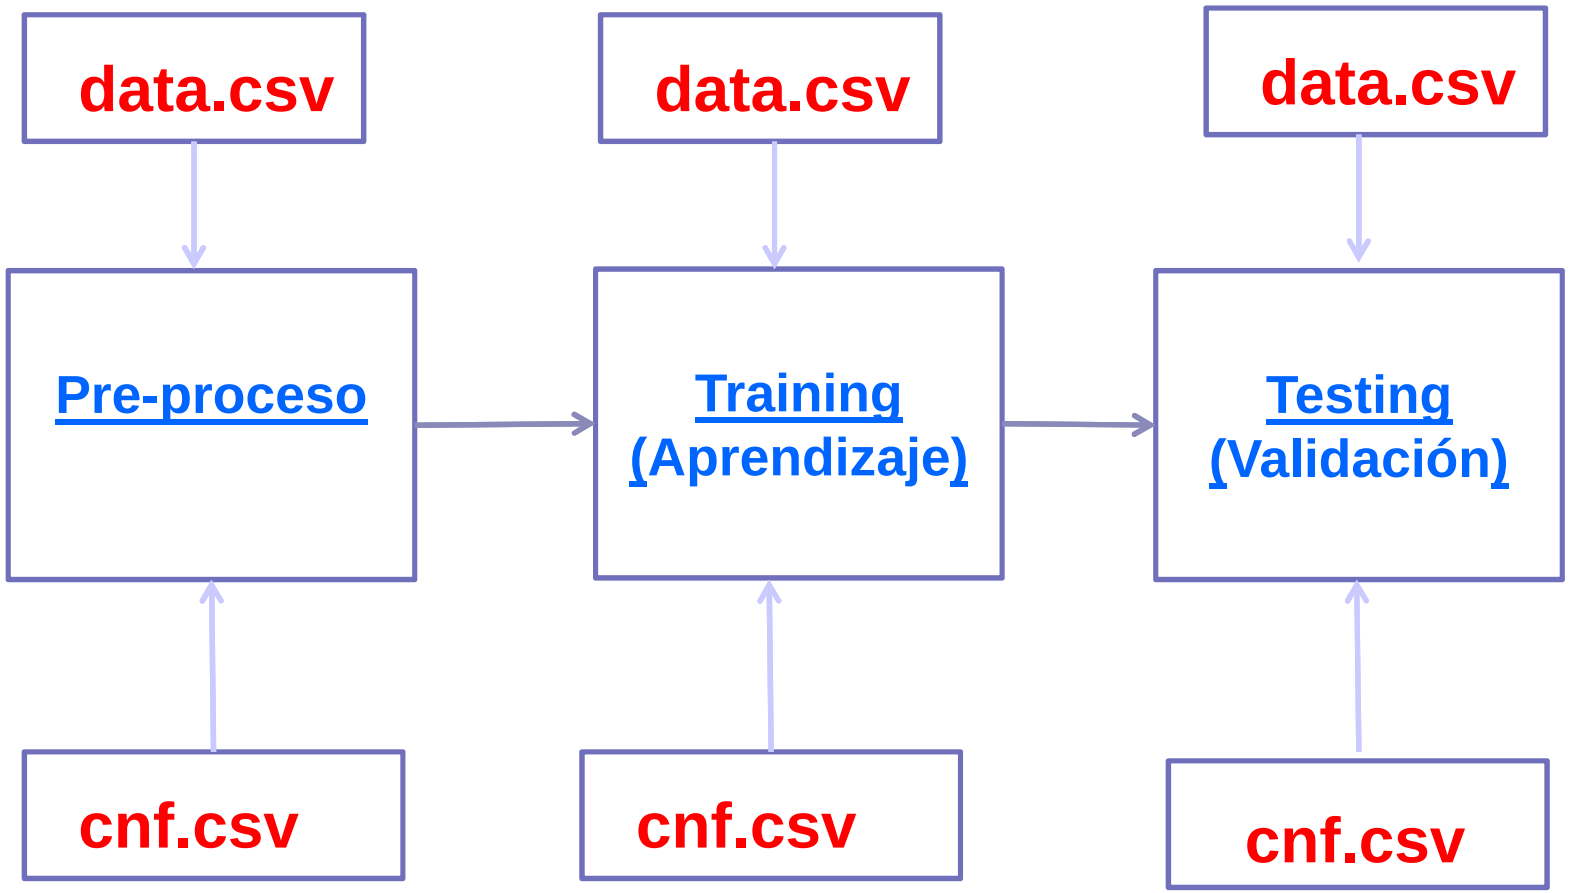

# Pre-proceso: prep.py

- Formato: Data**.csv** :
  - M-filas.
  - d-columnas.

- Donde:
  - **filas** : números de muestras.
  - **columnas**: número de variables.

# Pre-proceso: prep.py

- **Función Load_data():**
- Para cada Clase, Haga:
  - Crear una matriz de P-Filas por d-Columnas
    - P: representa el número de muestras
    - d: representa el número de variables.

# Pre-proceso: Create_Features()

- For i=1 to NbrClass
  - For j=1 to NbrVariables
    - X = data_class(Dat,j,i) # Retorna j-th variable de i-th class
    - F = Hankel_Features(X, nFrame, lFrame)
    - datF = Apilar_Features(F)
  - EndFor
  - Label = Binary_Label(i)
  - Y = Apilar_Label(Label)
  - X = Apilar_Features(datF)
- EndFor
- X= norm_data(X) #Usar ecuación dada en ppt actual.
- Create_dtrn_dtst(X,Y,p) # p: denota porcentaje de training.

# Pre-proceso: Hankel_Features()

- Para cada Frame, Haga :
  - Descomponga el *n*-Frame en *J*-niveles usando la matriz Hankel diádica y el método SVD.
  - Entropy_C:
    - Entropía de Amplitud Espectral para cada uno de los componentes de Hankel.
  - Svalues_C:
    - Valores Singulares de la Matriz de Componentes de Hankel usando el método SVD.
  - Crear el **n**-ésimo vector de características :
    - F(n,:) =[Entropy_C  Svalues_C]
      - La dimensión de F(n,:)= $2^J + 2^J$.

# Pre-proceso: Create_dtrn_dtst()

- **Re-ordenar aleatoriamente las posiciones de la data de entrada X y data de salida Y.**
- **Dividir la data X y data Y:**
  - Data Trainig: p (%)
    - xe, ye
  - Data Testing: (1-p) %
    - xv,yv
- **Crear archivo de training csv:**
  - dtrain.csv # para xe , ye
- **Crear archivo de testing csv:**
  - dtest.csv # para xe , ye

# train.py

- Cargar datos de configuración.
- Realizar el proceso de aprendizaje de la Red Neuronal Superficial (SNN) usando :
  - **Algoritmo Descenso del Gradiente Estocástico con Momemtum (SGDM).**

# Algoritmo de Aprendizaje MiniBatch:

# Stochastic Gradient Descent with Momentum (SGDM)

# Training de SNN con SGDM

- Considerar una base de datos de ***N***-muestras dada como:

$$\{X_i, Y_i\}_{i=1}^{N}, \quad X_i \in \Re^d, \; Y_i \in \Re^m$$

- $\mathbf{X_i}$ : representa la data de training
- $\mathbf{Y_i}$: representa la data deseada
- **d**: denota el número de variables de entrada
- **m**: denota en número de clases

# Algoritmo MiniBatch-SGDM

- **Paso 1**: Re-ordenar aleatoriamente la localización de cada muestra de la base de datos de training.

- **Paso 2**: Dividir las ***N***-muestras de la base de datos en Batch de ***M***-muestras.

$$B = \frac{N}{M}$$

$B$ : Número de Batch

- **Paso 3**: Entrenar la SNN usando un Número Máximo de Épocas (Iteraciones).
  - Cada Épocas ajusta los pesos de la SNN ***B***-veces vía el **SGDM**.

# Ajuste Pesos de Salida de SNN con SGDM

**Costo:**

$$E = \frac{1}{M}\sum_{n=1}^{M} C_n = \frac{1}{M}\sum_{n=1}^{M}\frac{1}{2}\sum_{k=1}^{m}\left(a_{k,n}^{(L)} - Y_{k,n}\right)^2$$

**Notación Matricial: Pesos de Salida**

$$w^{(L)}(\tau+1) = w^{(L)}(\tau) - v^{(L)}(\tau+1)$$
$$v^{(L)}(\tau+1) = \beta \times v^{(L)}(t) + \mu \times gW^{(L)}$$
$$\tau = 1,2,\ldots,\text{MaxIter}$$

**Notación Matricial: Gradiente**

$$gW^{(L)} = \frac{\partial E}{\partial w^{(L)}} = \delta^{(L)} \times \left(a^{(L-1)}\right)^T$$
$$\delta^{(L)} = e^{(L)} \otimes f'\left(z^{(L)}\right)$$

**Valores Iniciales:**

$$\beta, \mu \in (0,1),$$
$$w^{(L)}(0) = \text{random}$$
$$v^{(L)}(0) = w^{(L)}.shape$$
$$\mathrm{v}^{(L)}(0) = 0$$

# Ajuste Pesos Ocultos de SNN con SGDM

**Notación Matricial: Pesos Ocultos**

$$w^{(l)}(\tau+1) = w^{(l)}(\tau) - v^{(l)}(\tau+1)$$
$$v^{(l)}(\tau+1) = \beta \times v^{(l)}(\tau) + \mu \times gW^{(l)}$$
$$l = L-1, L-2, \ldots, 2, 1$$
$$\tau = 1, 2, \ldots, MaxIter$$

**Notación Matricial: Gradiente**

$$gW^{(l)} = \frac{\partial E}{\partial w^{(l)}} = \left\{ \left( w^{(l+1)} \right)^T \times \delta^{(l+1)} \right\} \otimes f'\left( z^{(l)} \right) \times \left( a^{(l-1)} \right)^T$$

**Valores Iniciales:**

$$w^{(l)}(0) = \text{random}$$
$$v^{(l)}(0) = w^{(l)}.shape$$
$$v^{(l)}(0) = 0$$

# Función de Activación : Capas Ocultas

- 1. ReLu:

$$f(x) = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases}, x \in \Re^d$$

- 2. L-ReLu:

$$f(x) = \begin{cases} 0.01\,x, & x < 0 \\ x, & x \geq 0 \end{cases}, x \in \Re^d$$

- 3. ELU:

$$f(x) = \begin{cases} a\left(e^x - 1\right), & x \leq 0 \\ x, & x > 0 \end{cases}, x \in \Re^d$$

- 4. SELU:

$$f(x) = \lambda \times \begin{cases} a\left(e^x - 1\right), & x \leq 0 \\ x, & x > 0 \end{cases}$$
$$x \in \Re^d,\ \lambda = 1.0507,\ a = 1.6732$$

- 5. Sigmoidal:

$$f(x) = \frac{1}{1 + e^{-z}},\ x \in \Re^d$$

# Función de Activación : Capas de Salida

- Sigmoidal:

$$f(x) = \frac{1}{1+e^{-z}}, \quad x \in \Re^d$$

# PseudoCode: train_snn()

```
Param = load_param()
W,V  = iniWs(Param)    # Setup Pesos
MSE = [];
For Iter =1 to MaxIter
  X,Y    = sort_data_ramdom(X,Y)
  [Cost W V] = trn_minibatch(X,Y,W,V, Param)
  MSE(Iter)   = mean(Cost)
  If mod(Iter,10)==0
        printf('\n Iterar-SGD:‘, Iter, MSE(Iter))
  EndIf
EndFor
```

# PseudoCode: trn_minibatch(X,Y,W,V, Param)

```
#N samples del dataset  X,  M-samples del Batch
nBtach  = N/M
For n=1 to nBatch
   Idx  =  get_Idx_n_Batch(n, M)
   xe    = X(:,Idx)
   ye    = Y(:,Idx)
   Act = forward(xe, W, Param)
   gW, Cost = gradW(Act, ye, W, Param)
   W, V       = upd_WV_sgdm(W, V, gW, Param)
EndFor
```

# train.py:

- **Cargar parámetros**
- **Cagar data de training**
- **Entrenar la SNN vía BP-SGDM**
- Crear archivo de costo (MSE):
  - **costo.csv**
    - T-filas por 1-columna.
  - Crear archivo de pesos:
    - **w_snn.npz.**

# test.py

- Cargar data de test.
- Cargas  peso entrenados.
- Realizar proceso  forward de SNN.
  - Crear archivo de Matriz de Confusión**:**
    - **cmatriz.csv**.
  - Crear archivo F-scores:
    - **fscores.csv**
    - (***m+1***)-filas por 1-columa
      - Fila *(m+1)*  representa el F-scores promedio de las ***m***-clases.

# Configuración: cnf.csv

- *Parámetros* :

- Línea 1: Número de Clases : 3
- Línea 2: Número de Frame : 50
- Línea 3: Tamaño del Frame : 256
- Línea 4: Nivel de Descomposición : 3
- Línea 5: Nodos Ocultos de $Capa_1$. : 40
- Línea 6: Nodos Ocultos de $Capa_2$. : 10
- Línea 7: Función Activación Oculta : 3

# Configuración : cnf.csv

- Línea 8: Porcentaje de Training : 0.8
- Línea 9: Tamaño miniBatch : 32
- Línea 10: Tasa de Aprendizaje : 0.1
- Línea 11: Coeficiente Beta : 0.8
- Línea 12: Número Máximo Iteraciones : 50
- ……
- ……..

# Normalización de Datos:

$$x = \frac{(x - x_{\min})}{(x_{\max} - x_{\min})} \times (b - a) + a, \quad a = 0.01 \qquad b = 0.99$$

# ENTREGA

- Lunes : 17/Abril/2022
  - Hora : 13:00 horas
  - Lugar : Aula Virtual del curso

- **Lenguaje Programación:**
  - Python version: 3.7.6 window (anaconda)
    - Numpy/Panda

# OBSERVACIÓN:

- Si un Grupo no Cumple con los requerimientos funcionales y no-funcionales, entonces la nota máxima será igual a 1,0 (uno coma cero).